


1. 請簡明扼要地闡述你如何抽取模型的輸入特徵 (feature)

答:

我先是把一天的資料, 18 個空氣汙染指標, 0 到 23 小時為一組, 之後再把剩下的 239 天依序排再第 1 天的後面, 這樣會得到一(18,5760)大小的矩陣.

再依序把 18 個空氣汙染指標的前 9 小時與第 10 小時為 pm2.5 的第 10 小時為一筆資料, 得到一個(1,163)的矩陣, 之後再連續排列這 18 個空氣汙染指標的前 10 個小時為一組資料, 最後會得到一個(5652,163)的矩陣, 這個矩陣就是我們的輸入資料.

2.請作圖比較不同訓練資料量對於 PM2.5 預測準確率的影響



答: 由上圖可知, 如果 train data 取 80% 的數量, 跟取 60% 的數量來比較, 這兩個的 error 相對是很接近的,

但是, 在 validation 取 80% 數量的 error 會比取 60% 數量的 error 來的小很多

3. 請比較不同複雜度的模型對於 PM2.5 預測準確率的影響

答:

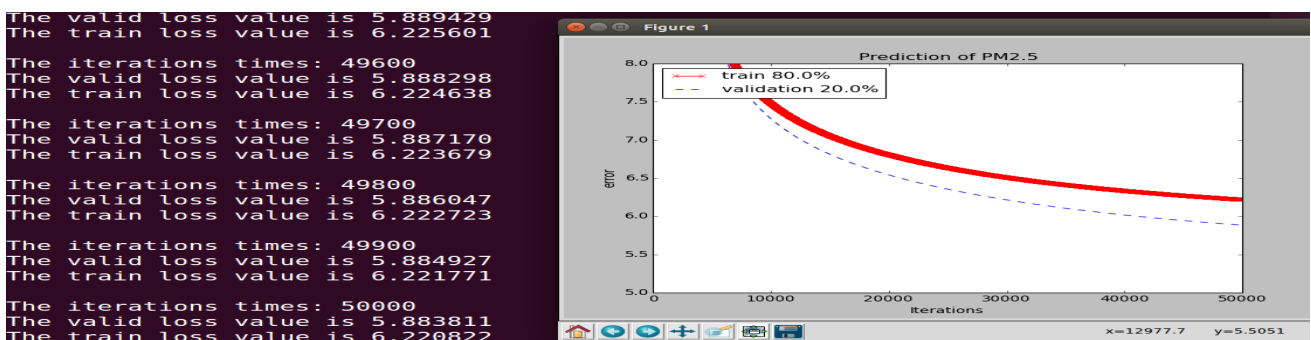


圖 1

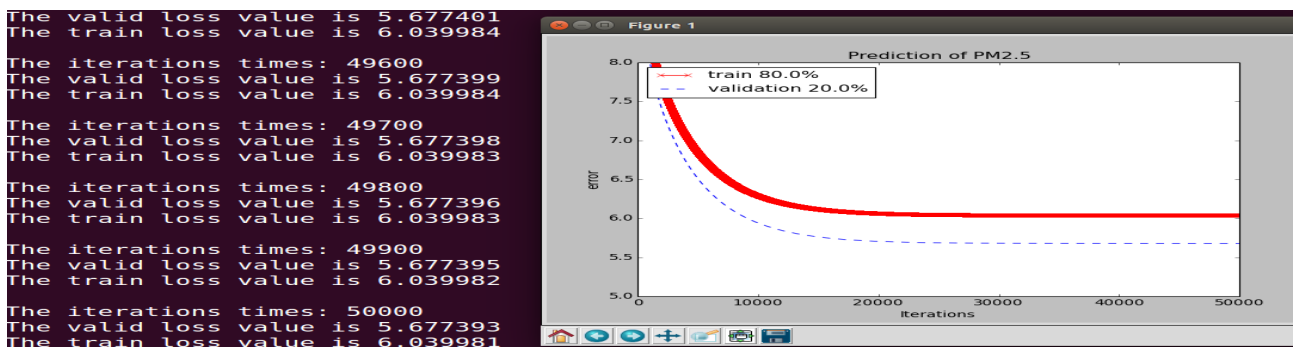


圖 2

抽取的 feature 越多，模型越複雜，那麼其特性是越接近非線性的曲線。

在 learning regression 中，模型越複雜，準確率也會愈來愈低。

例如：圖 1 中，我抽取 18 個空氣污染指標的前 9 小時來預測資料跟圖 2 只抽取 pm2.5 那筆空氣污染指標的 1~9 小時來預測資料；相比之下，只抽取 pm2.5 那筆空氣污染指標的 1~9 小時的 PM2.5 預測準確率會高於抽取 18 個空氣污染指標的前 9 小時，因為抽取 18 個空氣污染指標的前 9 小時的模型複雜度遠高於只抽取 pm2.5 那筆空氣污染指標的 1~9 小時的模型。

#### 4. 請討論正規化(regularization)對於 PM2.5 預測準確率的影響

答：

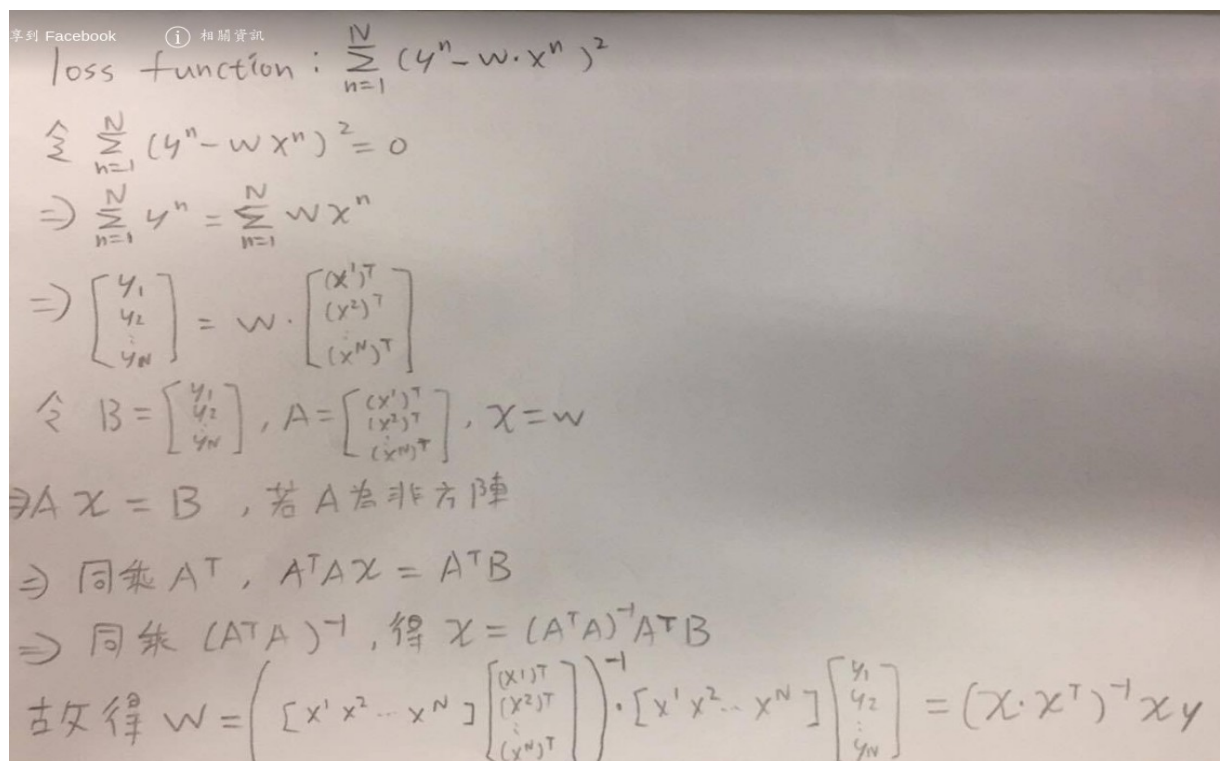
Regularization 即是調整 learning rate，可以減低 overfitting 的發生。

如果沒有 regularization，在 overfitting 的情況下，那麼在 training 過程中，training error 會變得小，但是 validation error 卻會增大，即對 PM2.5 的預測準確率會變差。

但是，如果加入 regularization 後，雖然能降低 overfitting 的發生，與讓 training error 和 validation error 的數值相近，卻會讓 error 的數值上升。

5. 在線性回歸問題中，假設有 N 筆訓練資料，每筆訓練資料的特徵 (feature) 為一向量  $x_n$ ，其標註(label)為一存量  $y_n$ ，模型參數為一向量  $w$  (此處忽略偏權值  $b$ )，則線性回歸的損失函數(loss function)為  $\sum_{n=1}^N (y_n - w \cdot x_n)^2$ 。若將所有訓練資料的特徵值以矩陣  $X = [x_1 \ x_2 \ \dots \ x_N]$  表示，所有訓練資料的標註以向量  $y = [y_1 \ y_2 \ \dots \ y_N]^T$  表示，請以  $X$  和  $y$  表示可以最小化損失函數的向量  $w$ 。

答：



Handwritten mathematical derivation for linear regression using matrix notation:

$$\begin{aligned} \text{loss function: } & \sum_{n=1}^N (y^n - w \cdot x^n)^2 \\ \hat{=} & \sum_{n=1}^N (y^n - w x^n)^2 = 0 \\ \Rightarrow & \sum_{n=1}^N y^n = \sum_{n=1}^N w x^n \\ \Rightarrow & \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = w \cdot \begin{bmatrix} (x^1)^T \\ (x^2)^T \\ \vdots \\ (x^N)^T \end{bmatrix} \\ \text{令 } & B = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}, A = \begin{bmatrix} (x^1)^T \\ (x^2)^T \\ \vdots \\ (x^N)^T \end{bmatrix}, x = w \\ \Rightarrow & A x = B, \text{ 若 } A \text{ 為非方陣} \\ \Rightarrow & \text{同乘 } A^T, A^T A x = A^T B \\ \Rightarrow & \text{同乘 } (A^T A)^{-1}, \text{ 得 } x = (A^T A)^{-1} A^T B \\ \text{故得 } & w = \left( [x^1 \ x^2 \ \dots \ x^N] \begin{bmatrix} (x^1)^T \\ (x^2)^T \\ \vdots \\ (x^N)^T \end{bmatrix} \right)^{-1} \cdot [x^1 \ x^2 \ \dots \ x^N] \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = (X \cdot X^T)^{-1} X y \end{aligned}$$